

Descobrendo Conhecimentos em Dados de Avaliação da Aprendizagem com Técnicas de Mineração de Dados

Edson P. Pimentel¹, Nizam Omar²

¹Universidade Municipal de São Caetano do Sul (IMES)
Av. Goiás, 3400 - 09550-051 - São Caetano do Sul - SP

²Universidade Presbiteriana Mackenzie
Rua da Consolação, 930 - 01302-907 - São Paulo - SP

edson.pimentel@imes.edu.br, omar@mackenzie.br

Abstract. *The continuous assessment learning process can generate a great amount of data making impracticable an human analysis. In turn, these data can hide useful information regarding the cognitive and metacognitive level of the learners and its real necessities of learning. Automatic or semi-automatic procedures for treatment and data analysis can help in this task. This paper describes a case study and presents a model for the application of data mining techniques in data collected through assessments in order to discover knowledge regarding an learner or of a learner group. The aim is to create mechanisms able to support formative assessment with suitable feedback for teacher and students.*

Key Words : Ongoing Assessment, Data Mining.

Resumo. *O processo contínuo de avaliação da aprendizagem pode gerar um grande volume de dados inviabilizando uma análise meramente humana. Estes dados podem esconder informações úteis a respeito do nível cognitivo e metacognitivo do aprendiz e das suas reais necessidades de aprendizagem. Procedimentos automáticos ou semi-automáticos para tratamento e análise de dados podem ajudar nesta tarefa. Este trabalho descreve um estudo de caso e apresenta um modelo para a aplicação de técnicas de mineração de dados a fim de descobrir conhecimentos a respeito de um aprendiz ou de um grupo, em dados coletados através de avaliações. Espera-se com isto criar mecanismos capazes de apoiar a avaliação formativa com feedback adequado para professor e aluno.*

Palavras-Chaves : Avaliação Formativa, Mineração de Dados.

1. Introdução

O processo de avaliação desempenha um papel fundamental em produzir informações que podem ajudar estudantes, pais, professores e administradores da educação. A avaliação é uma poderosa ferramenta educacional para promover a aprendizagem e é definida como uma medida do conhecimento e das habilidades do aprendiz, bem como de outras características que influenciam a aprendizagem e o desempenho, particularmente habilidades cognitivas e metacognitivas [Pellegrino et al. 2001].

Uma avaliação consistente com os princípios da aprendizagem deveria acontecer continuamente como parte da instrução e não apenas num momento final [Bransford et al. 2003, Perrenoud 1999] . Estas avaliações podem fornecer um conjunto de informações úteis a respeito do que o aluno sabe em cada conteúdo, diagnosticando as lacunas de aprendizagem que necessitam ser preenchidas para que ele possa dar o próximo passo. Os professores e os Sistemas de Tutoria Inteligente (STI) podem usar esta informação para adaptar a instrução ao encontro as necessidades do aprendiz. Da mesma forma, pesquisas comprovam que a aprendizagem efetiva acontece quando os aprendizes conseguem controlar a própria aprendizagem (metacognição) e quando estes possuem as habilidades necessárias para realizar as tarefas de avaliação [Broadfoot et al. 1999].

O processo de avaliação contínua da aprendizagem que tem por objetivo melhorar o processo de aprendizagem através do monitoramento da evolução do aprendiz, ao invés de simplesmente classificar os estudantes é essencial para aumentar a adaptabilidade dos sistemas e a personalização da Educação. No entanto, este processo de coleta de dados produzirá uma grande massa de dados no decorrer do tempo requerendo procedimentos automáticos ou semi-automáticos para tratamento e análise destes dados. Alguns trabalhos como o de [Silva and Vieira 2002] e [Lopes and Schiel 2004] têm tentado aplicar técnicas de mineração em dados obtidos a partir da interação do aprendiz com as ferramentas de comunicação (chat, fórum, email) no ensino à distancia.

Este trabalho tem como objetivo apresentar um modelo para a aplicação de técnicas de mineração de dados, utilizando algoritmos de extração de padrões para a descoberta de conhecimento em dados obtidos com avaliações de desempenho de um grupo de aprendizes, além de descrever um estudo de caso realizado.

O artigo está organizado como segue. A seção 3 apresenta conceitos sobre mineração de dados e algoritmos para extração de padrões. Na seção 3, descreve-se um estudo de caso aplicando técnicas de mineração em dados obtidos em sessões de avaliação da aprendizagem. Na seção 4 são feitas algumas considerações acerca deste trabalho e os aprofundamentos necessários.

2. Mineração de Dados e Descoberta de Conhecimentos

Com o avanço das tecnologias computacionais que permitem armazenar e processar uma grande quantidade de dados, novas tecnologias têm sido desenvolvidas para ajudar a extrair informação destas bases de dados, destacando-se o KDD - Knowledge Discovery in Database (Descoberta de Conhecimentos em Banco de Dados) e o Data Mining (Mineração de Dados).

KDD é o processo abrangente de descoberta de conhecimento útil, a partir de dados, enquanto mineração de dados restringe-se à aplicação de algoritmos de extração de padrões [Fayyad et al. 2002]. KDD é um campo multidisciplinar de pesquisa envolvendo as áreas de Banco de Dados, Estatística, Inteligência Artificial, Otimização, Visualização, dentre outras.

A maior parte das técnicas de KDD e Mineração de Dados pertencem à sub-área de Aprendizado de Máquina, um ramo da Inteligência artificial. O Aprendizado de Máquina - AM - estuda métodos computacionais para adquirir novos conhecimentos, novas habilidades e novos meios de organizar o conhecimento já existente [Mitchell 1997]. Este trabalho, utiliza a *Aprendizagem de Máquina* num sentido prático, ou seja, propõe a aplicação

de KDD na área de Educação, mais precisamente para encontrar e descobrir padrões em dados de Avaliação da Aprendizagem, focando-se na etapa de Mineração de Dados.

2.1. Mineração de Dados

Mineração de Dados (MD) pode ser definida como o processo automatizado de descoberta de novas informações a partir de grandes massas de dados, ou seja, um passo essencial no processo de descoberta de conhecimentos envolvendo o uso de diversas tarefas, técnicas e algoritmos [Rud 2001].

Qualquer aplicação de MD é dependente do contexto (área) em que ocorre. As novas informações descobertas, também chamadas de padrões, devem possuir algum grau de certeza para que sejam consideradas válidas, e precisam ser descritas em alguma linguagem compreendida pelos usuários para que possam realizar uma análise mais profunda.

O processo de mineração de dados envolve várias fases e etapas. Este trabalho classifica o processo de KDD em três grandes fases, com base nas abordagens descritas em [Silva and Vieira 2002] e [Rezende et al. 2003]: Preparação, Extração de Padrões e Pós-Processamento. Cada fase pode envolver uma ou mais etapas conforme mostra a tabela 1. No entanto, o KDD é um processo iterativo e algumas etapas podem ser realizadas novamente após a análise dos padrões encontrados de forma a melhorá-los.

Tabela 1. Fases e Etapas do processo de KDD

FASE	ETAPAS		OBJETIVO
Preparação	1	Seleção dos Dados	Compreender o domínio da aplicação, estabelecer objetivos e definir a massa de dados inicial a ser utilizada
	2	Pré-processamento e Limpeza	Eliminar eventuais inconsistências, incompletudes, problemas com tipos de dados, etc
	3	Transformação dos Dados	Transformar os dados para uma forma mais apropriada para a mineração, assumindo um formato mais estatístico e menos transacional
Extração de Padrões	4	Mineração dos Dados	Aplicar métodos (algoritmos) para a Extração de Padrões
Pós-Processamento	5	Avaliação dos Padrões	Analisar os resultados da etapa anterior a fim de identificar conhecimento nos padrões encontrados
	6	Apresentação do Conhecimento	Utilizar técnicas de visualização e representação do conhecimento para apresentar ao usuário o conhecimento minerado

2.2. Fases da Mineração

Na fase de **preparação** ocorre a identificação e o entendimento do problema, envolvendo a definição de objetivos e a escolha do melhor conjunto de dados para se realizar a extração de padrões. O passo seguinte é estruturar os dados de forma que possam passar pelo processo de extração de padrões. Normalmente estes dados estão espalhados em diversas tabelas e/ou bancos de dados (Data Warehouse). Esta etapa é responsável pela aplicação de métodos para o tratamento, limpeza e redução do volume de dados.

Na fase de **Extração de Padrões** escolhe-se inicialmente um ou mais algoritmos para a extração de conhecimentos. Esta fase pode ser executada várias vezes para o ajuste de parâmetros de forma a se obter os melhores resultados adequados aos objetivos estabelecidos. Esta fase compreende, portanto, a escolha das tarefas e técnicas de mineração e a extração dos padrões propriamente dita.

Na fase de **Pós-Processamento** o conhecimento extraído deve ser avaliado de forma a se verificar se pode ser utilizado para a tomada de decisões seja por um especialista humano ou por um sistema especialista. Algumas questões podem ser respondidas

nesta etapa: (a) O conhecimento extraído representa o conhecimento do especialista?
(b) De que maneira o conhecimento do especialista difere do conhecimento extraído?

2.3. Tarefas e Técnicas de Mineração

As tarefas são as classes de problemas determinadas de acordo com o tipo de conhecimento a ser minerado e também dos objetivos desejáveis para a solução. Já a escolha da técnica de mineração e do algoritmo a ser utilizado depende da tarefa que se quer executar.

A seguir, uma breve descrição das principais tarefas de mineração de dados destacando-se algumas técnicas e algoritmos dentro de cada tarefa baseado em [Rezende et al. 2003], [Silva and Vieira 2002] e [Witten and Frank 2005].

2.3.1. Classificação

É o processo que busca identificar propriedades comuns entre um conjunto de registros a fim de determinar a classe do registro. Para isto, cada registro possui um conjunto de atributos de predição e um atributo alvo. A principal técnica utilizada para a tarefa de classificação é a **Árvore de Decisão** (Decision Tree) que consiste em se escolher uma variável que se quer avaliar (atributo objetivo) e o algoritmo procura as características mais fortemente relacionadas a ela, montando uma árvore de ramificações na forma **SENTENÇA**, conforme figura 1.

A principal vantagem desta técnica é que o resultado é altamente compreensível para a maioria dos humanos. Dentre os algoritmos que implementam esta técnica destacam-se: ADTree, J4.8, Id3 e MSP.

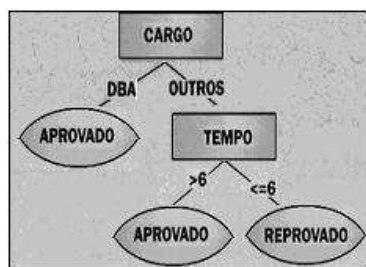


Figura 1. Árvore de Decisão

Associações	Suporte	Confiança
Leite => Ovos	5	0,83
Ovos => Leite	5	0,83
Leite => Café	4	0,67
Café => Leite	4	0,67
Leite => Açúcar	4	0,67
Açúcar => Leite	4	0,80
Leite => Manteiga	3	0,50

Figura 2. Apriori




Figura 3. K-Means

2.3.2. Associação

Estuda um padrão de relacionamento entre itens e dados, ou seja, dados dois conjuntos de atributos X e Y , a regra de associação tem a forma $X \rightarrow Y$, o que significa que os registros que contém o antecedente X tendem a conter o conseqüente Y . Por exemplo, uma análise de transações de compra em supermercado pode encontrar itens que tendem a ocorrer juntos em uma mesma compra.

O objetivo é saber se X implica Y . Esta implicação é avaliada através de dois fatores: suporte e confiança. O suporte representa o percentual de transações em que tal

regra aparece e confiança, ao invés de considerar todas as transações, trabalha apenas com as que possuem o antecedente da regra. A técnica de regra de associação implementa este tipo de tarefa através de algoritmos como o Apriori, DHP, ABS, sampling entre outros. Um exemplo de resultados fornecido pelo algoritmo Apriori é mostrado na figura 2.

2.3.3. Agrupamento ou Clusterização

Tem por finalidade agrupar um conjunto de dados utilizando algum critério de similaridade. Difere da tarefa de classificação uma vez que na clusterização os dados não devem ter sido previamente classificados (rotulados): o próprio algoritmo descobre as classes.

A técnica de particionamento implementa este tipo de tarefa sendo o algoritmo k-means o mais conhecido. Basicamente, o algoritmo divide o conjunto de dados em grupos (clusters), sendo necessário definir inicialmente o número de clusters que serão criados. Esse número é chamado de K e por isto o nome K-means. A figura 3 exibe um exemplo de visualização gráfica do resultado fornecido por este tipo de técnica.

3. Estudo de Caso

Para a aplicação das técnicas de mineração de dados utilizou-se dados coletados em 4 sessões de avaliação, com 52 participantes respondendo um total de 20 problemas de Lógica de Programação, envolvendo 12 conceitos diferentes e totalizando 3277 registros. O experimento foi realizado em sessões semanais e os problemas foram categorizados de acordo com os conteúdos exigidos na solução e níveis de dificuldade diferenciados. Cada sessão era composta de "n" enunciados de problemas.

As avaliações foram formuladas de forma a obter uma medida cognitiva e duas medidas metacognitivas. A medida cognitiva deveria retratar o real desempenho do estudante na resolução de cada problema e seria resultado do processo de correção do professor. A cada problema proposto foram associados os conteúdos exigidos para a sua solução e a correção foi feita atribuindo-se percentuais de acerto em cada conteúdo. As medidas metacognitivas deveriam indicar o grau de consciência do estudante em relação ao próprio nível de conhecimentos. Como medidas metacognitivas adotou-se o KMA - Knowledge Monitoring Accuracy (Precisão no Monitoramento do Conhecimento) e o KMB - Knowledge Monitoring Bias (Desvio no Monitoramento do Conhecimento), descritos mais detalhadamente em [Pimentel et al. 2005].

O índice KMA foi criado para medir e avaliar a diferença entre o conhecimento que o aprendiz julga possuir num domínio particular e o seu conhecimento real, constatado no seu desempenho nas avaliações [Everson and Tobias 2002]. Gama (2004) acrescentou ao KMA a possibilidade de prever e desempenhar também a resolução parcial dos problemas e criou o índice KMB para medir e identificar o tipo de desvio do aprendiz no julgamento de seu conhecimento, possibilitando identificar se o aprendiz é realista, otimista ou pessimista [Gama 2004].

Após ler o enunciado e refletir sobre o problema proposto cada participante deveria, nesta ordem: (a) prever o próprio desempenho; (b) tentar resolver o problema. A partir destas duas etapas (a e b) foi possível obter as duas medidas para cada estudante. A seguir, as etapas utilizadas para a aplicação de mineração sobre estes dados.

3.1. Preparação dos Dados

Esta etapa envolveu a seleção dos dados, o pré-processamento e limpeza e a transformação dos dados de forma mais apropriada para a mineração. A tabela 2 apresenta os atributos coletados neste estudo de caso e a sua descrição. Os atributos fazem parte basicamente de duas tabelas no modelo relacional de dados: Problemas e Itens Avaliados.

Tabela 2. Atributos coletados nas sessões de avaliação

Atributo	Tipo de Dados	Descrição do atributo
Idaluno	Número inteiro	Código que identifica o aluno participante da sessão de avaliação
IdSessao	Número inteiro	Identifica o número da sessão e a sequência temporal
Conceito	Nominal (CER, M-CER e ERR)	Grau de acerto do aprendiz, respectivamente: certo, meio certo, errado
Nível	Nominal (A ... E)	Nível de dificuldade de cada problema: escala de 'A' (fácil) a 'E' (difícil)
KMA	Nominal (ACER, AC-PAR e ERRO)	Medida Metacognitiva, respectivamente: acerto total previsão, acerto parcial na previsão e erro na previsão
KMB	Nominal (REALIS, M-OTI, M-PES, G-OTI e G-PES)	Medida Metacognitiva, respectivamente: realista, médio otimista, médio pessimista, grande otimista e grande pessimista
Item	Nominal (C01 a C12)	Código do conceito avaliado, podendo ser vários em cada problema (0: erro, 4: acerto parcial, 9: acerto total e ?: ausência de informação)

A figura 4 apresenta um extrato dos dados coletados e descritos na tabela 2, transformados para facilitar a tarefa de mineração.

Idaluno	Idsessao	Idprobl	nivel	conceito	kma	kmb	c01	c02	c03	c04	c05	c06	c07	c08	c09	c10	c11	c99
2	1	1	A	CER	AC-PAR	M-PES	9	9	9	?	9	9	?	?	?	?	?	9
2	1	2	A	CER	AC-PAR	M-PES	9	9	9	?	9	9	9	?	?	?	?	9
2	1	3	A	CER	AC-PAR	M-PES	9	9	9	?	9	9	9	?	?	?	?	9
2	1	4	B	CER	AC-PAR	M-PES	9	9	4	?	9	4	9	?	?	?	?	9
2	1	5	C	CER	AC-PAR	M-PES	9	9	0	?	9	9	?	4	?	?	?	9
2	1	6	D	CER	ERRO	G-PES	9	9	9	?	9	9	9	4	?	?	?	9
3	1	1	A	CER	ACER	REALIS	9	9	9	?	9	9	?	?	?	?	?	9
3	1	2	A	CER	ACER	REALIS	9	9	9	?	9	9	9	?	?	?	?	9

Figura 4. Extrato dos dados coletados transformados para a Mineração

Algumas questões podem ser formuladas na tentativa de descobrir conhecimento através dos algoritmos de reconhecimento de padrões da mesma forma que pode-se tentar encontrar conhecimento "não previsto". Eis alguns exemplos de questões:

- Existe relação entre os índices KMA e KMB e o desempenho do aprendiz?
- Quais conceitos são determinantes para desempenho final dos aprendizes ?
- Existe relação entre o desempenho e o nível de dificuldade: os alunos tiveram desempenho pior nos problemas classificados como "mais difícil" (nível E)?
- Quais os conceitos que o aluno sabe mais e quanto ele sabe ?

3.2. Mineração dos Dados

Para aplicar as técnicas de mineração de dados utilizou-se neste estudo de caso a ferramenta Weka (*Waikato Environment for Knowledge Analysis*) desenvolvida pela Universidade de Waikato da Nova Zelândia. Para mais informações consultar [Witten and Frank 2005]. A seguir, a descrição das duas tarefas de mineração de dados utilizadas neste estudo de caso: classificação e associação.

3.2.1. Tarefa de Classificação

Para esta tarefa foi necessário escolher um atributo alvo e os atributos de predição. Escolheu-se como atributo alvo o conceito obtido pelo aprendiz, ou seja, o "desempenho": certo meio-certo ou errado. De certo modo, a questão por trás desta escolha era "o que mais determina o desempenho do aprendiz ?" (os conceitos, o nível de dificuldade, os índices metacognitivos, etc).

O algoritmo de árvore de decisão escolhido foi o J4.8 que é a implementação da ferramenta WEKA para a técnica C.45, um tipo de árvore de classificação. A figura 5 apresenta parte da árvore de decisão gerada com base em 417 registros transformados a partir dos dados originais. Analisando-se os padrões encontrados pelo algoritmo J4.8 representados na árvore parcial da figura 5, pode-se fazer as seguintes leituras:

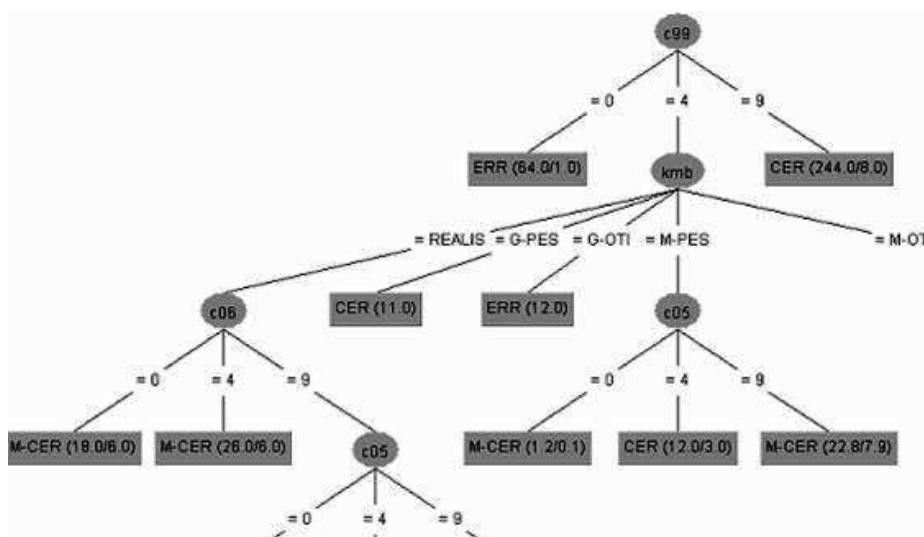


Figura 5. Árvore de Decisão parcial com o atributo alvo *desempenho*

- Em 244 ocorrências (mais de 50% dos casos), quando o aluno obtém a medida "9" (100% certo) no item C99 ele tem o desempenho final CER (certo). Quando obtém a medida "0" (100% errado) neste conceito, ele tem desempenho final ERR (errado) . Vale lembrar que o conceito C99 tinha peso de 30% na correção;
- Nota-se que quando o aluno obtém a medida "4" no conceito C99 o desempenho final depende da sua medida metacognitiva KMB, sendo:
 - Obtém desempenho CER (certo), se KMB=G-PES (grande pessimista);
 - Obtém desempenho ERR (errado), se KMB=G-OTI (grande otimista);
 - Se KMB = M-PES (médio pessimista) é preciso avaliar o desempenho no item C05 e se for REALIS(ta) é preciso avaliar o item C06.

Pode-se concluir com base nesta árvore de decisão que o desempenho pleno no item C99 é determinante para o desempenho final do participante no problema. Outros atributos alvos podem ser selecionados para fins de análises comparativas.

3.2.2. Tarefa de Associação

A figura 6 apresenta 10 regras geradas pelo algoritmo de regras de associação Apriori que na ferramenta WEKA possui as seguintes características: (a) tenta gerar 10 regras de associação; (b) o valor de confiança default é 90%; (c) o valor de suporte mínimo começa com 100% e vai diminuindo 5% até que as 10 regras sejam formadas; (d) as regras geradas são ordenadas de acordo com o valor de confiança;

```
Best rules found:
1. knb=REALIS 216 ==> kna=ACER 216      conf:(1)
2. kna=ACER 216 ==> knb=REALIS 216      conf:(1)
3. c03=9 c05=9 c99=9 193 ==> dconceito=CER 193      conf:(1)
4. c05=9 c99=9 214 ==> dconceito=CER 213      conf:(1)
5. c05=9 c06=9 c99=9 195 ==> dconceito=CER 194      conf:(0.99)
6. c03=9 c99=9 215 ==> dconceito=CER 212      conf:(0.99)
7. c03=9 c06=9 c99=9 193 ==> dconceito=CER 190      conf:(0.98)
8. c06=9 c99=9 217 ==> dconceito=CER 213      conf:(0.98)
9. c99=9 244 ==> dconceito=CER 236      conf:(0.97)
10. c01=9 c99=9 204 ==> dconceito=CER 197      conf:(0.97)
```

Figura 6. Regras de associação geradas pelo algoritmo Apriori

Analisando-se os padrões encontrados as seguintes leituras podem ser feitas:

- Na regra 1, com confiança de 100% (conf =1), o KMB é realista (REALIS) em 216 casos em que o KMA é igual a certo (ACER) também em 216 casos;
- Na regra 3, com confiança de 100% têm-se que quando o aprendiz obtém medida de desempenho "9" (acerto total) nos conceitos C03, C05 e C99 ele obtém um conceito final (dconceito) igual a certo (CER);
- As regras de 4 a 10 também apresentam relações entre o grau de acerto do participante em vários conceitos e o seu desempenho final.

4. Conclusões e Aprofundamentos Necessários

O processo de avaliação continua pode gerar uma **grande massa de dados** que precisa ser tratada e interpretada de modo a fornecer informações mais precisas acerca do conhecimento atual do aprendiz. Este volume pode se tornar maior ainda se pensarmos a possibilidade do cruzamento entre as disciplinas e seus pré-requisitos.

As técnicas de mineração de dados aplicadas neste trabalho demonstraram ser viáveis e aplicáveis em dados coletados através de avaliações. Os resultados obtidos demonstraram as potencialidades destas técnicas sendo necessário, no entanto, um aprofundamento nos testes e análises dos padrões encontrados, além de estudar outros atributos que possam ser incorporados tais como estratégias adotadas na solução, tipos de erros, critérios, objetivos, etc. Além disso, para que estas técnicas possam ser aplicadas massivamente por professores, requer-se o desenvolvimento de uma interface amigável ou até mesmo de um ambiente integrado de avaliação.

Referências

Bransford, J., Brown, A. L., Cocking, R. R., and Council, N. R. (2003). *How People Learn: Brain, Mind, Experience, and School: Expanded Edition*. National Academy Press, Washington, D.C. National Research Council.

- Broadfoot, P., Daugherty, R., Gardner, J., Gipps, C., Harlen, W., James, M., and Stobart, G. (1999). *Assessment for learning: Beyond the black box*. Technical report, University of Cambridge, School of Education. Assessment Reform Group - ARG.
- Everson, H. T. and Tobias, S. (2002). *Knowing what you know and what you don't: Further research on metacognitive knowledge monitoring*. Technical Report 3, The College Board Research Report.
- Fayyad, U., Grinstein, G. G., and Wierse, A. (2002). *Information Visualization In Data Mining And Knowledge Discovery*. Morgan Kaufmann Publishers Inc, SAN FRANCISCO, CA, USA.
- Gama, C. (2004). *Towards a model of Metacognition Instruction in Interactive Learning Environments*. Doutorado, University of Sussex, Inglaterra.
- Lopes, C. C. and Schiel, U. (2004). Uma estratégia para aplicar mineração de dados no acompanhamento do aprendizado na ead. In *Anais do XIII Seminco*, Blumenau, SC. FURB.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill.
- Pellegrino, J. W., Chudowsky, N., Glaser, R., and Council, N. R. (2001). *Knowing what students know: The science and design of educational assessment*. National Academy Press, New York.
- Perrenoud, P. (1999). *Avaliação : da excelência à regulação das aprendizagens - entre duas lógicas*. Artmed, Porto Alegre.
- Pimentel, E. P., Omar, N., and de França, V. F. (2005). Um modelo para a incorporação de automonitoramento da aprendizagem em sti. In *Revista Brasileira de Informática na Educação - RBIE*, volume 13, Porto Alegre, RS.
- Rezende, S. O., Pugliesi, J. B., Melanda, E. A., and de Paula, M. F. (2003). Mineração de dados. In Rezende, S. O., editor, *Sistemas Inteligentes: Fundamentos e Aplicações*, pages 307–335, Barueri, SP. Manole.
- Rud, O. P. (2001). *Data Mining Cookbook : Modeling Data for Marketing, Risk and Customer Relationship Management*. Willey Computer Publishing, New York.
- Silva, D. R. and Vieira, M. T. P. (2002). Using data warehouse and data mining resources for ongoing assessment in distance learning. In *The Second IEEE International Conference on Advanced Learning Technologies*, Kazan, Russia.
- Witten, I. H. and Frank, E. (2005). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, San Francisco, CA, 2nd edition.